MAGÍSTER EN CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL

MCDI501: Estadística Computacional para la Toma de Decisiones

Evaluación Formativa 2

Modelamiento Predictivo (práctica)

Notebook grupal · 0 % (formativa)

Título del proyecto:	Predicción de riesgo de enfermedad coronaria a 10 años
Integrantes:	Felipe Díaz Toro, Pablo Ríos Passteni, Guillermo Subiabre Chacón, Ninoska Yévenes Hernández
Dataset:	Framingham Heart Study (Riesgo Cardiovascular)
Docente:	Jean Paul Maidana
Fecha:	20/10/2026
Repositorio GitHub:	`https://github.com/fdiaztoro/proyecto-grupo3-mcdi501`

Información de la evaluación

Fase del proyecto: Fase 3: Desarrollo del proyecto
Modalidad: Grupal **Ponderación:** 0 % (formativa)
Entregable: Notebook `.ipynb` ejecutable, con síntesis final en Markdown
Resultado de aprendizaje (RA3): evaluar modelos de regresión para problemas de predicción y clasificación en contextos de negocio o ingeniería.
Indicadores: ID3.1, ID3.2.
Prerrequisito: Sumativas 1 y 2 completadas (usarán sus resultados).

Conexión con evaluaciones anteriores

Esta práctica formativa **no es independiente**: requiere el uso explícito de los resultados de S1 y S2 (selección de variables, tratamiento de outliers, correlaciones validadas y parámetros robustos), y prepara directamente la Evaluación Sumativa 3.

Índice

1 Preparación de datos para modelamiento **2**
1.1 Hallazgos de S1 y S2 . . . 2
1.2 Tratamiento de faltantes, partición y estandarización . . . 2

2 Modelo de regresión logística **2**
2.1 Selección de variables . . . 2
2.2 Ajuste e interpretación . . . 3
2.3 Diagnóstico: VIF . . . 3

3 Evaluación de desempeño predictivo **3**
3.1 Matriz de confusión y métricas . . . 3
3.2 Curva ROC y AUC . . . 5

4 Síntesis y reflexión **5**

5 Bibliografía (APA 7) **6**

1. Preparación de datos para modelamiento

1.1 Hallazgos de S1 y S2

El punto de partida no es el dato crudo, sino lo aprendido en S1 (exploración e inferencia) y S2 (validación con remuestreo).

Variable	r con CHD (S1)	IC bootstrap 95 % (S2)
Edad	0,225	[0,197; 0,254]
Presión sistólica	0,216	[0,183; 0,250]
Hipertensión prevalente	0,178	no validada en S2
Glucosa	0,126	no validada en S2
Diabetes	0,097	no validada en S2
Sexo masculino	0,088	no validada en S2
Colesterol total	0,082	no validada en S2
IMC	0,075	no validada en S2
Cigarrillos por día	0,058	no validada en S2

Las variables más asociadas con CHD son la edad ($r = 0,225$) y la presión sistólica ($r = 0,216$); S2 confirmó que ambas son estables, con IC bootstrap estrechos que no incluyen el cero. S2 solo validó con remuestreo estas dos correlaciones: las demás candidatas cuentan únicamente con el valor puntual de S1, sin ese respaldo adicional, y se declara explícitamente en la tabla. Todas las correlaciones son modestas (máximo 0,23), lo esperable en un fenómeno multifactorial a 10 años.

Hay faltantes en siete variables, ninguna sobre el 10 %: glucosa concentra la mayoría (388 casos, 9,2 %), seguida de educación (105, 2,5 %); los 29 faltantes de cigarrillos por día (0,7 %) son todos fumadores actuales. La regla de Tukey marca 3,0 % de valores extremos en presión sistólica, 4,9 % en glucosa, 0,3 % en cigarrillos por día y 0 % en edad; S1 mostró que son plausibles (glucosas $\geq$200 mg/dL corresponden a personas diabéticas), por lo que no se eliminan.

1.2 Tratamiento de faltantes, partición y estandarización

Estrategia simple, en este orden: (1) partición 70/30 estratificada con scikit-learn (Pedregosa et al., 2011) por `TenYearCHD`, (2) tope de la glucosa, (3) imputación con medianas y (4) estandarización. Todo se calcula con el conjunto de entrenamiento y se aplica al de prueba, para evitar fuga de información.

La partición deja 2.966 participantes en train y 1.272 en test, con prevalencia de CHD casi idéntica (15,21 % y 15,17 %). La glucosa se acota al percentil 99 de train (187,1 mg/dL), calculado solo con el 70 % de los datos. Los faltantes se imputan con la mediana de train; en cigarrillos por día se usa la mediana de los **fumadores** de train (20 cigarrillos/día), porque los 29 faltantes son fumadores actuales y la mediana general es 0, que los habría tratado como no fumadores. Tras estandarizar, los cinco predictores quedan con media 0 y desviación 1 en train, de modo que sus coeficientes serán comparables entre sí.

2. Modelo de regresión logística

2.1 Selección de variables

Se seleccionan cinco predictores con un criterio doble: que la asociación con CHD aparezca en S1 y, cuando S2 la validó, que resista el remuestreo: **edad**, **presión sistólica**, **glucosa**, **sexo masculino** y **cigarrillos por día**. Se excluyen la presión diastólica y la hipertensión prevalente ($r = 0,78$ y $r = 0,70$ con la sistólica, S2), diabetes (solapada con glucosa, $r = 0,62$) y colesterol total/IMC (asociaciones débiles, 0,082 y 0,075). Con unos 451 casos de CHD en train hay cerca

de 90 por predictor, margen amplio para cinco variables.

2.2 Ajuste e interpretación

El modelo logístico (`statsmodels.Logit`; Seabold y Perktold, 2010) sobre los cinco predictores estandarizados mejora de forma clara sobre el nulo (LLR $p < 0,001$) y explica una fracción moderada de la variación (pseudo $R^2 = 0,117$).

Variable	Coef.	Odds Ratio	p-valor	Sig. ($\alpha = 0,05$)
Constante	$-1,991$	0,137	$< 0,001$	Sí
Edad	0,608	1,837	$< 0,001$	Sí
Presión sistólica	0,404	1,497	$< 0,001$	Sí
Sexo masculino	0,201	1,223	0,0005	Sí
Cigarrillos por día	0,291	1,338	$< 0,001$	Sí
Glucosa	0,154	1,166	0,0008	Sí

Los cinco predictores son significativos al 5 % ($p \leq 0,0008$). Como están estandarizados, cada odds ratio se lee "por cada desviación estándar de aumento en la variable, manteniendo las demás constantes". La edad tiene el mayor efecto (OR = 1,84), coherente con ser la variable más correlacionada en S1; le sigue la presión sistólica (OR = 1,50). Cigarrillos por día (OR = 1,34) y glucosa (OR = 1,17) también aumentan el riesgo: el tabaquismo sí aporta en el modelo multivariable, aunque S2 no distinguiera de cero su correlación marginal. El sexo masculino (OR = 1,22) también es significativo.

2.3 Diagnóstico: VIF

Variable	VIF
Edad	1,23
Presión sistólica	1,20
Sexo masculino	1,12
Cigarrillos por día	1,17
Glucosa	1,03

Todos los VIF están muy por debajo del umbral de 5: no hay evidencia de multicolinealidad relevante, consistente con que 2.1 ya excluyó los pares fuertemente correlacionados. Si hubiera aparecido un VIF > 5, la solución habría sido eliminar una de las variables del par colineal o, alternativamente, combinarlas en un índice compuesto o usar regularización (Ridge).

3. Evaluación de desempeño predictivo

3.1 Matriz de confusión y métricas

Con el modelo de 2.2 se predijo la probabilidad de CHD de los 1.272 participantes de prueba y se clasificó como CHD con el umbral por defecto de 0,5 (Figura 1). De los 193 casos reales (15,2 %), el modelo marca como CHD solo a 23 personas (9 verdaderos y 14 falsos positivos) y deja pasar a 184 (falsos negativos).

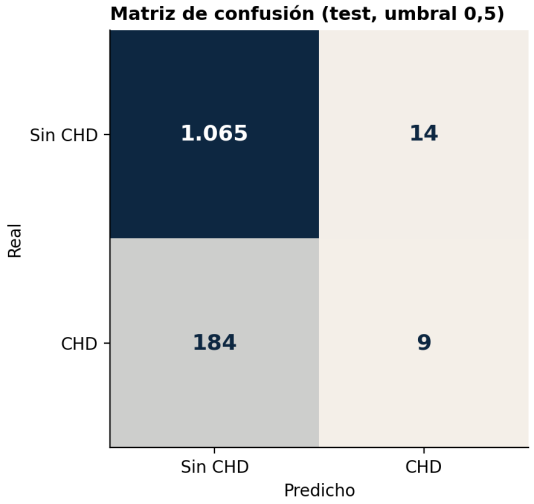


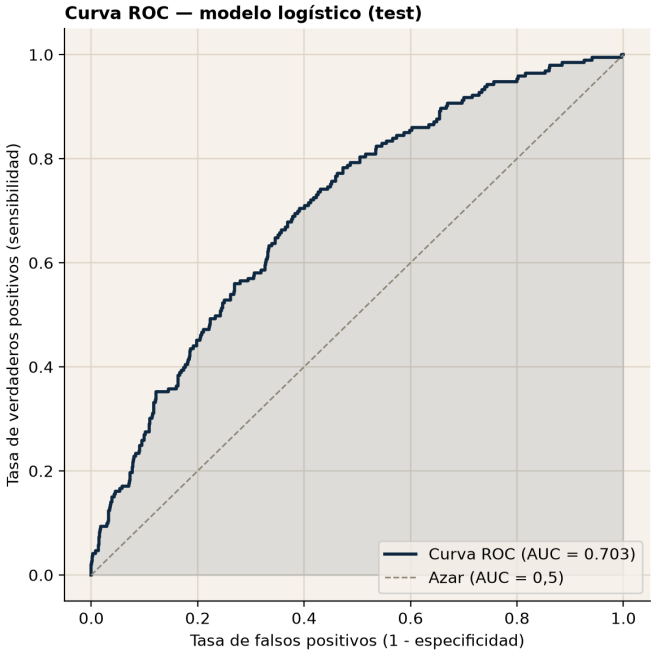
Figura 1: Matriz de confusión en el conjunto de prueba (umbral 0,5).

Tabla 1: Métricas de clasificación en el conjunto de prueba (clase CHD).

Métrica	**Valor**
Accuracy	0,844
Precision	0,391
Recall (sensibilidad)	0,047
F1-score	0,083

La accuracy (84,4 %) es engañosa: un clasificador trivial que dijera "sin CHD" para todos alcanzaría 84,8 %, algo más. La precision (39,1 %) es más del doble de la prevalencia, pero se basa en muy pocas predicciones positivas. El recall es la métrica crítica en salud, porque no detectar a quien desarrollará CHD es el error más costoso, y aquí es de solo 4,7 % (9 de 193). El F1 (0,083) refleja ese desequilibrio. Con una prevalencia de 15,2 % la probabilidad predicha casi nunca supera 0,5, así que el umbral por defecto no es adecuado; el AUC de 3.2 muestra que el modelo sí ordena a los participantes por riesgo. Para S3 conviene ponderar las clases y elegir el umbral con criterio.

3.2 Curva ROC y AUC



El AUC en test es 0,703, dentro del rango "aceptable" (0,7-0,8) de la escala de referencia (Hosmer et al., 2013): el modelo discrimina mejor que el azar (AUC = 0,5) pero está lejos de un desempeño "bueno" (0,8-0,9) o "excelente" ($> 0,9$). Es consistente con que las correlaciones individuales de S1 fueron modestas (máximo 0,225): cinco predictores con asociaciones moderadas producen una capacidad discriminativa moderada, no alta. El AUC evalúa el modelo en todos los umbrales posibles, a diferencia de las métricas de 3.1, que dependen del umbral fijo de 0,5; ambas secciones se complementan.

4. Síntesis y reflexión

Cómo integramos S1 y S2. No partimos de cero: usamos la misma copia versionada del dataset (Dileep, 2019; SHA-256) verificada en S1 y S2, para que los resultados fueran comparables. De S1 heredamos el desbalance (15,2 % de CHD), los faltantes y los valores extremos plausibles; en particular, los 29 faltantes de cigarrillos por día son fumadores actuales, así que los imputamos con la mediana de los fumadores y no con la general (que es 0 y los habría tratado como no fumadores). De S2 usamos la validación por bootstrap: edad y presión sistólica tienen correlaciones estables con el CHD y entraron al modelo; como S2 mostró que la presión diastólica ($r = 0,78$) y la hipertensión prevalente ($r = 0,70$) forman un bloque colineal con la sistólica, dejamos solo una de las tres, y el VIF (máx. 1,23) confirmó esa decisión. También heredamos el tope de la glucosa (1.2), pensado para su cola extrema. Elegimos las cinco variables con un criterio doble: que la asociación apareciera en S1 y, cuando S2 la validó, que resistiera el bootstrap.

Un hallazgo a destacar: S2 mostró que *fumador actual* no se distingue de cero de forma marginal, pero esa es otra variable que *cigarrillos por día*, que S2 no validó. En el modelo, cigarrillos por día es significativa (OR = 1,34 por desviación estándar) y ya lo es solo en un modelo simple (OR = 1,18; $p < 0,001$). Su efecto aumenta al controlar por edad (OR = 1,40), porque los fumadores son más jóvenes (47,7 frente a 51,5 años; correlación −0,19) y la edad, que eleva mucho el riesgo, oculta parte del efecto del tabaco.

Qué nos dice el desempeño. Por dentro, el modelo nos convence: los cinco predictores son significativos ($p \leq 0,0008$), sin multicolinealidad y con un AUC de 0,703 (aceptable), es decir,

ordena con capacidad moderada el riesgo de los participantes; el pseudo R^2 (0,117) también es moderado, lo esperable con asociaciones individuales modestas. Pero con el umbral de 0,5 el desempeño práctico es malo: el recall es de solo 4,7 % (9 de 193 casos) y la accuracy (84,4 %) ni le gana al clasificador trivial (84,8 %). No lo vemos como una contradicción, sino como el síntoma esperado de evaluar un problema desbalanceado (prevalencia 15,2 %) con un umbral que nunca se pensó para esa prevalencia. En salud, no detectar a quien desarrollará CHD es el error más costoso, por lo que el modelo no es utilizable tal como está.

Lo que nos proponemos mejorar en la Sumativa 3.

1. Ponderar las clases o mover el umbral de decisión (en vez de 0,5 fijo), para mejorar el recall.
2. Aplicar bootstrap a los coeficientes y odds ratios (como en S2) y a las métricas, para reportar IC: con solo 193 casos en el test, las métricas son muy inciertas.
3. Comparar 2 o 3 modelos con distintos criterios de selección de variables (forward, backward, AIC/BIC) y elegir por AUC y recall, no por accuracy.
4. Usar validación cruzada (k-fold) en vez de un solo split train/test.
5. Imputar la glucosa (9,2 % de faltantes) por regresión en vez de mediana.
6. Ajustar con y sin las observaciones influyentes de S2 (filas 481, 2909, 3160, 2197 y 781) y verificar la linealidad en el logit.

5. Bibliografía (APA 7)

Dileep. (2019). *Logistic regression to predict heart disease* (Versión 1) [Conjunto de datos]. Kaggle. `https://www.kaggle.com/datasets/dileep070/heart-disease-prediction-using-logistic-regression`

Hosmer, D. W., Lemeshow, S., & Sturdivant, R. X. (2013). *Applied logistic regression* (3.ª ed.). Wiley. `https://doi.org/10.1002/9781118548387`

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.

Seabold, S., & Perktold, J. (2010). statsmodels: Econometric and statistical modeling with Python. En S. van der Walt & J. Millman (Eds.), *Proceedings of the 9th Python in Science Conference* (pp. 92–96). `https://doi.org/10.25080/Majora-92bf1922-011`