



MAGÍSTER EN CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL

MCDI501: Estadística Computacional para la Toma de Decisiones

Evaluación Sumativa 1

Análisis Exploratorio e Inferencial

Predicción de riesgo de enfermedad coronaria a 10 años

Framingham Heart Study

Informe técnico grupal · Grupo 3 · 20 %

Título del proyecto:	Predicción de riesgo de enfermedad coronaria a 10 años
Integrantes:	Felipe Díaz Toro, Pablo Ríos Passteni, Guillermo Subiabre Chacón, Ninoska Yévenes Hernández
Dataset:	Framingham Heart Study (Riesgo Cardiovascular)
Docente:	Jean Paul Maidana
Fecha:	09/10/2026
Repositorio GitHub:	https://github.com/fdiaztoro/proyecto-grupo3-mcdi501

Información de la evaluación

Fase del proyecto: Fase 2: Búsqueda y recopilación de información

Modalidad: Grupal (3–4 integrantes) **Ponderación:** 20 % de la nota final

Entregables: Informe PDF (máx. 8 págs., sin anexos) · Notebook .ipynb · Repositorio GitHub

Resultado de aprendizaje (RA1): aplicar probabilidad e inferencia estadística en problemas de decisión bajo incertidumbre.

Indicadores: ID1.2, ID1.3, ID1.4.

Recuerden: los resultados de esta sumativa serán la entrada de S2 y S3.

Índice

1 Preparación y carga de datos	1
2 Análisis exploratorio de datos	2
2.1 Estadística descriptiva	2
2.2 Análisis bivariado	3
3 Estimación de parámetros	4
4 Pruebas de hipótesis	5
4.1 Prueba 1: diferencia de edad entre quienes desarrollan CHD y quienes no	5
4.2 Prueba 2: asociación entre hipertensión prevalente y CHD	5
4.3 Prueba 3: asociación entre sexo y CHD	6
5 Informe de avance del proyecto	6
6 Notebook y repositorio GitHub	7
7 Bibliografía	7

1. Preparación y carga de datos

El proyecto utiliza la versión pública en Kaggle del **Framingham Heart Study** (Dileep, s.f.), uno de los estudios de cohorte cardiovascular más influyentes (Mahmood et al., 2014). Reúne **4.238 participantes** y 16 variables: la variable objetivo **TenYearCHD**, que indica si la persona desarrolló **enfermedad coronaria (CHD) en los diez años siguientes**, y 15 predictores medidos al inicio del seguimiento. El conjunto se carga en Python con **kagglehub** y **pandas**; todas las columnas llegan como numéricas, pero corresponden a seis indicadores binarios (sexo, fumador actual, medicación antihipertensiva, ACV previo, hipertensión prevalente y diabetes), una variable ordinal (nivel educativo, 1 a 4), un conteo (cigarrillos por día) y siete variables numéricas (edad, colesterol total, presión sistólica y diastólica, IMC, frecuencia cardíaca y glucosa).

La revisión de calidad muestra un conjunto limpio en estructura. No hay filas duplicadas ni inconsistencias entre variables relacionadas: ninguna presión diastólica iguala o supera a la sistólica, el hábito de fumar es coherente con los cigarrillos por día y las binarias solo toman los valores 0 y 1. Hay **datos faltantes en siete variables** (Figura 1b): la glucosa concentra 388 (9,2 %) y el nivel educativo 105 (2,5 %); el resto no supera el 1,3 %. En total, 582 filas (13,7 %) tienen al menos

un faltante. Para orientar su tratamiento se comparó la tasa de CHD con y sin dato de glucosa: la diferencia no es significativa ($\chi^2 = 1,58$; $p = 0,21$), un indicio de que la pérdida no depende del desenlace. Los valores extremos según la regla de Tukey van de 1,3 % (colesterol) a 4,9 % (glucosa) de las observaciones y son clínicamente plausibles: los 34 registros con glucosa de 200 mg/dL o más corresponden todos a personas diabéticas. La Tabla 1 documenta las decisiones.

Tabla 1: Decisiones de limpieza y tratamiento de datos.

Situación	Decisión
Faltantes en 7 variables (13,7 % de las filas)	Se trabaja con los casos disponibles de cada variable; la imputación se aborda en el modelamiento.
Glucosa faltante (9,2 %)	No se asocia con CHD ($p = 0,21$); se usan los casos con dato.
Cigarrillos por día faltantes (29)	Los 29 son fumadores actuales; podrán imputarse con la mediana de los fumadores.
Valores extremos (Tukey)	Se conservan por ser plausibles (glucosa ≥ 200 solo en diabéticos); se usa la mediana como referencia y en los gráficos se recorta la cola solo para visualizar.
Duplicados e inconsistencias	No se detectaron; no requieren tratamiento.

2. Análisis exploratorio de datos

2.1 Estadística descriptiva

La Tabla 2 resume las variables numéricas. La edad es la única casi simétrica (media 49,58, mediana 49 y asimetría 0,23). El colesterol, la presión sistólica y el IMC tienen asimetría moderada a la derecha, con la media por sobre la mediana, y la glucosa es la más sesgada (6,21), arrastrada por los valores altos de las personas diabéticas. En cigarrillos por día la mediana es 0 y la media 9: más de la mitad no fuma y la media la elevan los fumadores intensos.

Tabla 2: Medidas descriptivas de las variables numéricas (casos disponibles de cada variable).

Variable	Media	Mediana	Desv. est.	Mín.	Máx.	Asimetría	<i>n</i>
Edad (años)	49,58	49,00	8,57	32	70	0,23	4.238
Cigarrillos por día	9,00	0,00	11,92	0	70	1,25	4.209
Colesterol total (mg/dL)	236,72	234,00	44,59	107	696	0,87	4.188
Presión sistólica (mmHg)	132,35	128,00	22,04	83,5	295	1,15	4.238
Presión diastólica (mmHg)	82,89	82,00	11,91	48	142,5	0,71	4.238
IMC (kg/m ²)	25,80	25,40	4,08	15,54	56,8	0,98	4.219
Frecuencia cardíaca (lpm)	75,88	75,00	12,03	44	143	0,64	4.237
Glucosa (mg/dL)	81,97	78,00	23,96	40	394	6,21	3.850

Entre las variables categóricas (Tabla 3), el 42,9 % son hombres, el 49,4 % fuma y el 31,1 % tiene hipertensión prevalente. La tasa de CHD es mayor en quienes tienen cada antecedente, salvo el tabaquismo, que casi no la cambia. El nivel educativo se concentra en el nivel 1 (41,6 %), que tiene además la mayor tasa de CHD (18,8 %). La variable objetivo está **desbalanceada**: 644 participantes (15,2 %) desarrollan CHD, unas 5,6 personas sanas por cada caso (Figura 1a).

Tabla 3: Variables binarias: prevalencia y tasa de CHD a 10 años según el atributo.

Variable	% con atributo	% CHD (con)	% CHD (sin)
Sexo masculino	42,9	18,9	12,4
Fumador actual	49,4	15,9	14,5
Medicación antihipertensiva	3,0	33,1	14,6
ACV previo	0,6	44,0	15,0
Hipertensión prevalente	31,1	24,7	10,9
Diabetes	2,6	36,7	14,6




Figura 1: (a) Distribución de la variable objetivo. (b) Porcentaje de datos faltantes por variable.

La Figura 2 confirma las formas: la edad se reparte de forma aproximadamente simétrica en torno a 50 años, mientras que el colesterol y la presión sistólica tienen la mediana (234 mg/dL y 128 mmHg) bajo la media y una cola de valores altos.




Figura 2: Distribución de tres variables numéricas, con su media o mediana de referencia (colesterol recortado al percentil 99 solo para visualizar).

2.2 Análisis bivariado

La matriz de correlaciones (Figura 3) muestra pares muy relacionados: presión sistólica y diastólica ($r = 0,78$), fumador actual y cigarrillos por día ($r = 0,77$, en parte estructural), hipertensión prevalente y presión sistólica ($r = 0,70$) y diabetes y glucosa ($r = 0,62$), lo que anticipa colinealidad si se modelan juntos. Con el objetivo, todas las correlaciones lineales son débiles; las mayores son la edad ($r = 0,23$), la presión sistólica ($r = 0,22$) y la hipertensión ($r = 0,18$). Cuando una de las variables es binaria, el coeficiente de Pearson equivale al punto biserial (binaria con numérica) o al coeficiente phi (binaria con binaria).




Figura 3: Matriz de correlaciones entre las variables predictoras (triángulo inferior).

Como la correlación resume mal la relación con un desenlace binario poco frecuente, se construyeron dos variables categóricas: el tramo etario (decenios) y la categoría de presión sistólica, con cortes cercanos a los umbrales clínicos (normal bajo 120 mmHg, elevada de 120 a 129 e hipertensión desde 130; Whelton et al., 2018). La Figura 4 muestra que la tasa de CHD crece de forma **monótona** con ambas: del 4,1 % entre los 32 y 39 años al 27,7 % entre los 60 y 70 (casi siete veces más), y del 8,5 % bajo 120 mmHg al 30,8 % desde 160 mmHg. Son relaciones mucho más marcadas de lo que sugieren sus correlaciones, y señalan a la edad y la presión arterial como los ejes del riesgo.




Figura 4: Tasa de CHD a 10 años por tramo etario y por categoría de presión sistólica, con la media global de referencia.

3. Estimación de parámetros

Se estimaron cuatro parámetros poblacionales con un 95 % de confianza (Tabla 4). Para las medias de tres variables numéricas se usó el intervalo basado en la aproximación normal, $\bar{x} \pm z_{0,975} EE$ con $EE = s/\sqrt{n}$, justificado por el Teorema Central del Límite dado el tamaño de la muestra (Wasserman, 2004). Para la proporción de CHD se usó la misma aproximación (método de Wald), $\hat{p} \pm z_{0,975} \sqrt{\hat{p}(1 - \hat{p})/n}$. Cada intervalo usa los casos disponibles, sin imputar.

Tabla 4: Estimación puntual e intervalos de confianza al 95 %.

Parámetro	Estimación	IC 95 %	Mediana	<i>n</i>	Método
Edad media (años)	49,58	[49,33; 49,84]	49	4.238	Normal (TCL)
Colesterol total medio (mg/dL)	236,72	[235,37; 238,07]	234	4.188	Normal (TCL)
Presión sistólica media (mmHg)	132,35	[131,69; 133,02]	128	4.238	Normal (TCL)
Proporción de CHD a 10 años	15,20 %	[14,12 %; 16,28 %]	–	4.238	Normal (Wald)

Los intervalos son estrechos por el tamaño muestral. Con un 95 % de confianza, la edad media poblacional está entre 49,33 y 49,84 años, la presión sistólica media entre 131,69 y 133,02 mmHg y la proporción de personas que desarrollan CHD a 10 años entre 14,12 % y 16,28 %; el intervalo de Wilson, alternativa para proporciones, prácticamente coincide ([14,15 %; 16,31 %]).

La estimación tiene **limitaciones** que conviene declarar. El colesterol y la presión sistólica son asimétricos: el TCL respalda la normalidad de la *media muestral*, pero la media queda por sobre el valor típico, por eso se informa también la mediana. El colesterol se estimó sin 50 casos faltantes (1,2 %); si la pérdida no fuera aleatoria podría introducir un sesgo, aunque pequeño. Por último, los intervalos suponen que la muestra representa a la población de interés, y la cohorte proviene de una sola ciudad de Estados Unidos, por lo que la generalización debe hacerse con cautela.

4. Pruebas de hipótesis

Se aplicaron tres pruebas con nivel de significancia $\alpha = 0,05$, valor habitual en estudios aplicados que equilibra los errores de tipo I y II, eligiendo el procedimiento según el tipo de variable. El tamaño del efecto se interpreta con los criterios de Cohen (1988).

4.1 Prueba 1: diferencia de edad entre quienes desarrollan CHD y quienes no

$$H_0 : \mu_{\text{CHD}} = \mu_{\text{no CHD}} \quad \text{vs.} \quad H_1 : \mu_{\text{CHD}} \neq \mu_{\text{no CHD}}$$

Supuestos. Los grupos son independientes, la edad es aproximadamente simétrica en ambos (asimetría de $-0,25$ y $0,32$) y, con 644 y 3.594 personas, el TCL respalda la prueba *t*. Como los tamaños son muy dispares, se usa la prueba *t* de Welch, que no asume varianzas iguales (Welch, 1947); la prueba de Levene no detecta diferencia de varianzas al 5 % ($p = 0,053$) y la *t* de Student lleva a la misma decisión ($t = 15,05$).

Resultado. La edad media es 54,15 años en quienes desarrollan CHD y 48,77 en quienes no, una diferencia de 5,38 años (IC 95 %: 4,70 a 6,06). El estadístico es $t = 15,58$ con $p < 0,001$, de modo que **se rechaza** H_0 , con un efecto moderado (d de Cohen = 0,64; Figura 5a). La edad es un marcador de riesgo relevante, pero por sí sola no separa nítidamente a ambos grupos.

4.2 Prueba 2: asociación entre hipertensión prevalente y CHD

$$H_0 : \text{hipertensión prevalente y CHD son independientes} \quad \text{vs.} \quad H_1 : \text{están asociadas}$$

Supuestos. Se usa la prueba χ^2 de independencia sobre una tabla de 2×2 con observaciones independientes; la frecuencia esperada mínima es 200, muy por encima del umbral de 5.

Resultado. El 24,7 % de quienes tienen hipertensión desarrolla CHD, frente al 10,9 % de quienes no (Figura 5b). La asociación es significativa ($\chi^2 = 132,6$; gl = 1; $p < 0,001$), por lo que **se rechaza** H_0 , con intensidad débil (V de Cramér = 0,18). El riesgo relativo es de 2,26 y la razón de momios de 2,68: la hipertensión más que duplica el riesgo y es un criterio simple y accionable para priorizar el seguimiento.

4.3 Prueba 3: asociación entre sexo y CHD

H_0 : sexo y CHD son independientes vs. H_1 : están asociados

Supuestos. Prueba χ^2 de independencia sobre una tabla de 2×2 ; la frecuencia esperada mínima es 276, por lo que el supuesto se cumple.

Resultado. El 18,9 % de los hombres desarrolla CHD, frente al 12,4 % de las mujeres. La asociación es significativa ($\chi^2 = 32,6$; gl = 1; $p < 0,001$), por lo que **se rechaza H_0** , aunque con intensidad muy débil ($V = 0,09$; riesgo relativo de 1,52 y razón de momios de 1,64). La diferencia no se explica por la edad ni por la hipertensión, que son prácticamente iguales entre sexos (49,3 frente a 49,8 años; 31,3 % frente a 30,8 %). El sexo aporta una señal propia, más débil que la edad o la hipertensión.




Figura 5: (a) Distribución de la edad por grupo (rombo: media). (b) Tasa de CHD a 10 años según hipertensión prevalente y sexo.

5. Informe de avance del proyecto

El problema es de decisión bajo incertidumbre: anticipar, en atención primaria, qué personas tienen mayor probabilidad de desarrollar enfermedad coronaria en diez años, para priorizar su control y prevención. En esta fase se revisó la calidad de los datos y se documentó su tratamiento, se caracterizó el conjunto con estadística descriptiva y gráficos según el tipo de variable, se exploraron relaciones bivariadas con variables derivadas, se estimaron parámetros con intervalos de confianza y se contrastaron tres hipótesis con la prueba t de Welch y la prueba χ^2 de independencia. Estos resultados profundizan los de la Formativa 1 y son coherentes con ellos.

Los resultados ofrecen tres lecturas. La **edad** y la **presión arterial** son las señales más claras: el riesgo crece de forma monótona con ambas y la hipertensión más que duplica la probabilidad de CHD. El **sexo masculino** aporta una señal adicional, más débil. En cambio, el tabaquismo casi no se asocia con el desenlace de forma aislada. Como advertencias, el desbalance del objetivo (15,2 %) exigirá evaluar los modelos con métricas sensibles a la clase minoritaria y no solo con la exactitud, y la colinealidad entre presión sistólica, diastólica e hipertensión obliga a no incluirlas juntas sin más. Los datos son observacionales, por lo que las asociaciones no implican causalidad.

Los **próximos pasos** son imputar los faltantes (glucosa, nivel educativo y cigarrillos por día en fumadores), evaluar el efecto de los valores extremos, validar las estimaciones mediante remuestreo en la Sumativa 2 y entrenar modelos de clasificación en la Sumativa 3.

6. Notebook y repositorio GitHub

Todo el análisis se realizó en Python con `pandas` (McKinney, 2010), `numpy` (Harris et al., 2020), `scipy` (Virtanen et al., 2020) y `matplotlib` (Hunter, 2007). El cuaderno `Sumativa1_FraminghamHeartStudy_Codigo.ipynb` sigue el mismo orden de este informe, descarga los datos, genera todas las tablas y figuras aquí incluidas y fija la semilla 42 para asegurar la reproducibilidad. El código y los informes de cada evaluación están en el repositorio enlazado en la portada.

7. Bibliografía

- Cohen, J. (1988). *Statistical power analysis for the behavioral sciences* (2.^a ed.). Lawrence Erlbaum Associates.
- Dileep. (s.f.). *Heart disease prediction using logistic regression* [Conjunto de datos]. Kaggle. <https://www.kaggle.com/datasets/dileep070/heart-disease-prediction-using-logistic-regression>
- Harris, C. R., Millman, K. J., van der Walt, S. J., Gommers, R., Virtanen, P., Cournapeau, D., ... Oliphant, T. E. (2020). Array programming with NumPy. *Nature*, 585(7825), 357–362. <https://doi.org/10.1038/s41586-020-2649-2>
- Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering*, 9(3), 90–95. <https://doi.org/10.1109/MCSE.2007.55>
- Mahmood, S. S., Levy, D., Vasan, R. S., & Wang, T. J. (2014). The Framingham Heart Study and the epidemiology of cardiovascular disease: A historical perspective. *The Lancet*, 383(9921), 999–1008. [https://doi.org/10.1016/S0140-6736\(13\)61752-3](https://doi.org/10.1016/S0140-6736(13)61752-3)
- McKinney, W. (2010). Data structures for statistical computing in Python. En *Proceedings of the 9th Python in Science Conference* (pp. 56–61). <https://doi.org/10.25080/Majora-92bf1922-00a>
- Virtanen, P., Gommers, R., Oliphant, T. E., Haberland, M., Reddy, T., Cournapeau, D., ... SciPy 1.0 Contributors. (2020). SciPy 1.0: Fundamental algorithms for scientific computing in Python. *Nature Methods*, 17(3), 261–272. <https://doi.org/10.1038/s41592-019-0686-2>
- Wasserman, L. (2004). *All of statistics: A concise course in statistical inference*. Springer.
- Welch, B. L. (1947). The generalization of “Student’s” problem when several different population variances are involved. *Biometrika*, 34(1–2), 28–35. <https://doi.org/10.1093/biomet/34.1-2.28>
- Whelton, P. K., Carey, R. M., Aronow, W. S., Casey, D. E., Collins, K. J., Dennison Himmelfarb, C., ... Wright, J. T. (2018). 2017 ACC/AHA/AAPA/ABC/ACPM/AGS/APhA/ASH/ASPC/NMA/PCNA guideline for the prevention, detection, evaluation, and management of high blood pressure in adults. *Hypertension*, 71(6), e13–e115. <https://doi.org/10.1161/HYP.0000000000000065>