



MAGÍSTER EN CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL

MCDI501: Estadística Computacional para la Toma de Decisiones

Evaluación Sumativa 1

Análisis Exploratorio e Inferencial

Predicción de riesgo de enfermedad coronaria a 10 años

Framingham Heart Study

Informe técnico grupal · Grupo 3 · 20 %

Título del proyecto:	Predicción de riesgo de enfermedad coronaria a 10 años
Integrantes:	Felipe Díaz Toro, Pablo Ríos Passteni, Guillermo Subiabre Chacón, Ninoska Yévenes Hernández
Dataset:	Framingham Heart Study (Riesgo Cardiovascular)
Docente:	Jean Paul Maidana
Fecha:	09/10/2026
Repositorio GitHub:	https://github.com/fdiaztoro/proyecto-grupo3-mcdi501

1. Preparación y carga de datos

El problema es anticipar el riesgo de CHD a diez años, con atención primaria como contexto de aplicación propuesto. Esta fase caracteriza los datos, estima parámetros y contrasta asociaciones preliminares; no valida todavía un predictor clínico.

El proyecto utiliza la versión pública en Kaggle del **Framingham Heart Study** (Dileep, s.f.), uno de los estudios de cohorte cardiovascular más influyentes (Mahmood et al., 2014). Reúne **4.238 participantes** y 16 variables: la variable objetivo **TenYearCHD**, que indica si la persona desarrolló **enfermedad coronaria (CHD) en los diez años siguientes**, y 15 predictores medidos al inicio del seguimiento. El conjunto se carga en Python con **kagglehub** y **pandas**; todas las columnas llegan como numéricas, pero corresponden a seis indicadores binarios (sexo, fumador actual, medicación antihipertensiva, ACV previo, hipertensión prevalente y diabetes), una variable ordinal (nivel educativo, 1 a 4), un conteo (cigarrillos por día) y siete variables numéricas (edad, colesterol total, presión sistólica y diastólica, IMC, frecuencia cardíaca y glucosa).

La revisión de calidad muestra un conjunto limpio en estructura. La educación respeta los códigos 1–4 y no se detectan valores no positivos en las mediciones numéricas ni conteos negativos de cigarrillos. Estas reglas no certifican plausibilidad clínica. No hay filas duplicadas ni inconsistencias entre variables relacionadas: ninguna presión diastólica iguala o supera a la sistólica, el hábito de fumar es coherente con los cigarrillos por día y las binarias solo toman los valores 0 y 1. Hay **datos faltantes en siete variables** (detalle por variable en el notebook): la glucosa concentra 388 (9,2 %) y el nivel educativo 105 (2,5 %); el resto no supera el 1,3 %. En total, 582 filas (13,7 %) tienen al menos un faltante. Para orientar su tratamiento se comparó la tasa de CHD con y sin dato de glucosa: la diferencia no es significativa ($\chi^2 = 1,58$; $p = 0,21$), sin evidencia suficiente para rechazar la independencia. Esto no identifica el mecanismo de ausencia ni descarta sesgo por trabajar con casos disponibles. Los valores extremos según la regla de Tukey van de 1,3 % (colesterol) a 4,9 % (glucosa) de las observaciones y son clínicamente plausibles: los 34 registros con glucosa de 200 mg/dL o más corresponden todos a personas diabéticas. La Tabla 1 documenta las decisiones.

Tabla 1: Decisiones de limpieza y tratamiento de datos.

Situación	Decisión
Faltantes en 7 variables (13,7 % de las filas)	Se trabaja con los casos disponibles de cada variable; la imputación se aborda en el modelamiento.
Glucosa faltante (9,2 %)	No se detectó asociación con CHD ($p = 0,21$); no se demuestra ausencia aleatoria. Se usan casos disponibles.
Cigarrillos por día faltantes (29)	Los 29 son fumadores actuales; podrán imputarse con la mediana de los fumadores.
Valores extremos (Tukey)	Se conservan por ser plausibles (glucosa ≥ 200 solo en diabéticos); se usa la mediana como referencia y las distribuciones se muestran sin modificar los valores.
Duplicados e inconsistencias	No se detectaron; no requieren tratamiento.

2. Análisis exploratorio de datos

2.1 Estadística descriptiva

La Tabla 2 resume las variables numéricas. La edad es la única casi simétrica (media 49,58, mediana 49 y asimetría 0,23). El colesterol, la presión sistólica y el IMC tienen asimetría moderada a la derecha, con la media por sobre la mediana, y la glucosa es la más sesgada (6,21), arrastrada por los valores altos de las personas diabéticas. En cigarrillos por día la mediana es 0 y la media 9: más de la mitad no fuma y la media la elevan los fumadores intensos.

Tabla 2: Medidas descriptivas de las variables numéricas (casos disponibles de cada variable).

Variable	Media	Mediana	Desv. est.	Mín.	Máx.	Asimetría	n
Edad (años)	49,58	49,00	8,57	32	70	0,23	4.238
Cigarrillos por día	9,00	0,00	11,92	0	70	1,25	4.209
Colesterol total (mg/dL)	236,72	234,00	44,59	107	696	0,87	4.188
Presión sistólica (mmHg)	132,35	128,00	22,04	83,5	295	1,15	4.238
Presión diastólica (mmHg)	82,89	82,00	11,91	48	142,5	0,71	4.238
IMC (kg/m ²)	25,80	25,40	4,08	15,54	56,8	0,98	4.219
Frecuencia cardíaca (lpm)	75,88	75,00	12,03	44	143	0,64	4.237
Glucosa (mg/dL)	81,97	78,00	23,96	40	394	6,21	3.850

Entre las variables categóricas (Tabla 3), el 42,9 % son hombres, el 49,4 % fuma y el 31,1 % tiene hipertensión prevalente. La tasa de CHD es mayor en quienes tienen cada antecedente, salvo el tabaquismo, que casi no la cambia. El nivel educativo se concentra en el nivel 1 (41,6 %), que tiene además la mayor tasa de CHD (18,8 %). Las frecuencias educativas sobre 4.133 casos válidos son nivel 1: 1.720 (41,6 %); nivel 2: 1.253 (30,3 %); nivel 3: 687 (16,6 %); nivel 4: 473 (11,4 %). Hay 105 faltantes. La variable objetivo está **desbalanceada**: 644 participantes (15,2 %) desarrollan CHD, unas 5,6 personas sin CHD registrada por cada caso. La Figura 1 representa las demás categóricas; la distribución del objetivo también se grafica en el notebook.

Tabla 3: Frecuencias de las variables binarias. El porcentaje usa casos válidos; 0: sin atributo, 1: con atributo (sexo: mujer/hombre).

Variable	n ₀	n ₁	n válido	Faltantes	% con atributo
Sexo masculino	2.419	1.819	4.238	0	42,9
Fumador actual	2.144	2.094	4.238	0	49,4
Medicación antihipertensiva	4.061	124	4.185	53	3,0
ACV previo	4.213	25	4.238	0	0,6
Hipertensión prevalente	2.922	1.316	4.238	0	31,1
Diabetes	4.129	109	4.238	0	2,6
CHD a diez años	3.594	644	4.238	0	15,2




Figura 1: Frecuencias relativas: (a) presencia de atributos binarios; (b) nivel educativo, con conteos absolutos. Los denominadores excluyen faltantes.

La Figura 2 confirma las formas: la edad se reparte de forma aproximadamente simétrica en torno a 50 años, mientras que el colesterol y la presión sistólica tienen la mediana (234 mg/dL y 128 mmHg) bajo la media y una cola de valores altos.




Figura 2: Distribución de tres variables numéricas, con su media o mediana de referencia (valores completos, sin recorte de la cola).

2.2 Análisis bivariado

La matriz de correlaciones (Figura 3) muestra pares muy relacionados: presión sistólica y diastólica ($r = 0,78$), fumador actual y cigarrillos por día ($r = 0,77$, en parte estructural), hipertensión prevalente y presión sistólica ($r = 0,70$) y diabetes y glucosa ($r = 0,62$), lo que anticipa colinealidad si se modelan juntos. Con el objetivo, todas las correlaciones lineales son débiles; las mayores son la edad ($r = 0,23$), la presión sistólica ($r = 0,22$) y la hipertensión ($r = 0,18$). Cuando una de las variables es binaria, el coeficiente de Pearson equivale al punto biserial (binaria con numérica) o al coeficiente phi (binaria con binaria).




Figura 3: Matriz de correlaciones entre las variables predictoras (triángulo inferior).

Para complementar las correlaciones con tasas por grupos, se construyeron dos variables categóricas: el tramo etario (decenios) y la categoría de presión sistólica, con cortes cercanos a los umbrales clínicos (cortes de 120, 130, 140 y 160 mmHg, sin constituir un diagnóstico; Whelton et al., 2018). La Figura 4 muestra que la tasa de CHD crece de forma **monótona** con ambas: del 4,1 % entre los 32 y 39 años al 27,7 % entre los 60 y 70 (casi siete veces más), y del 8,5 % bajo 120 mmHg al 30,8 % desde 160 mmHg. Las tasas y correlaciones describen aspectos distintos de las asociaciones observadas; no establecen efectos independientes ni causales.




Figura 4: Tasa de CHD a 10 años por tramo etario y por categoría de presión sistólica, con la media global de referencia.

3. Estimación de parámetros

Se estimaron cuatro parámetros poblacionales con un 95 % de confianza (Tabla 4). Para las medias de tres variables numéricas se usó $\bar{x} \pm t_{0,975;n-1} s/\sqrt{n}$, porque la desviación poblacional es desconocida; el tamaño muestral respalda la aproximación para medias (Wasserman, 2004). Para la proporción de CHD se usó Wilson, comparándolo con Wald en el notebook. Cada intervalo usa los casos disponibles, sin imputar.

Tabla 4: Estimación puntual e intervalos de confianza al 95 %.

Parámetro	Estimación	IC 95 %	Mediana	n	Método
Edad media (años)	49,58	[49,33; 49,84]	49	4.238	Student
Colesterol total medio (mg/dL)	236,72	[235,37; 238,07]	234	4.188	Student
Presión sistólica media (mmHg)	132,35	[131,69; 133,02]	128	4.238	Student
Proporción de CHD a 10 años	15,20 %	[14,15 %; 16,31 %]	–	4.238	Wilson

Los intervalos son estrechos por el tamaño muestral. Con un 95 % de confianza, la edad media poblacional está entre 49,33 y 49,84 años, la presión sistólica media entre 131,69 y 133,02 mmHg y la proporción de personas que desarrollan CHD a 10 años entre 14,15 % y 16,31 % (Wilson); Wald ofrece valores muy próximos ([14,12 %; 16,28 %]).

La estimación tiene **limitaciones** que conviene declarar. El colesterol y la presión sistólica son asimétricos: el TCL respalda la normalidad de la *media muestral*, pero la media queda por sobre el valor típico, por eso se informa también la mediana. El colesterol se estimó sin 50 casos faltantes (1,2 %); si la pérdida no fuera aleatoria podría introducir un sesgo cuya magnitud no se deduce solo del porcentaje faltante. Por último, los intervalos suponen independencia y que la muestra representa a la población de interés, y la cohorte proviene de una sola ciudad de Estados Unidos, por lo que la generalización debe hacerse con cautela.

4. Pruebas de hipótesis

Se aplicaron tres pruebas con nivel de significancia $\alpha = 0,05$, valor habitual en estudios aplicados fijado para esta fase exploratoria. Controla el error de tipo I por contraste bajo sus supuestos, pero no determina el error de tipo II ni la potencia. Se añade Holm para las tres pruebas sustantivas. El tamaño del efecto se interpreta con los criterios de Cohen (1988).

4.1 Prueba 1: diferencia de edad entre quienes desarrollan CHD y quienes no

$$H_0 : \mu_{\text{CHD}} = \mu_{\text{no CHD}} \quad \text{vs.} \quad H_1 : \mu_{\text{CHD}} \neq \mu_{\text{no CHD}}$$

Supuestos. Se asume independencia entre personas; el archivo no verifica parentesco o agrupamiento. La edad es aproximadamente simétrica en ambos (asimetría de $-0,25$ y $0,32$) y, con 644 y 3.594 personas, el TCL respalda la prueba t . Como los tamaños son muy dispares, se usa la prueba t de Welch, que no asume varianzas iguales (Welch, 1947); la prueba de Levene no detecta diferencia de varianzas al 5 % ($p = 0,053$) y la t de Student lleva a la misma decisión ($t = 15,05$).

Resultado. La edad media es 54,15 años en quienes desarrollan CHD y 48,77 en quienes no, una diferencia de 5,38 años (IC 95 %: 4,70 a 6,06). El estadístico es $t = 15,58$ con $p < 0,001$, de modo que **se rechaza** H_0 , con un efecto moderado (d de Cohen = 0,64; Figura 5a). La edad es un marcador de riesgo relevante, pero por sí sola no separa nítidamente a ambos grupos.

4.2 Prueba 2: asociación entre hipertensión prevalente y CHD

$$H_0 : \text{hipertensión prevalente y CHD son independientes} \quad \text{vs.} \quad H_1 : \text{están asociadas}$$

Supuestos. Se usa la prueba χ^2 de independencia sobre una tabla de 2×2 con observaciones independientes (supuesto de diseño); la frecuencia esperada mínima es 200, por encima de 5. La prueba incorpora Yates; V de Cramér utiliza el estadístico sin corrección.

Resultado. El 24,7 % de quienes tienen hipertensión desarrolla CHD, frente al 10,9 % de quienes no (Figura 5b). La asociación es significativa ($\chi^2 = 132,6$; $gl = 1$; $p < 0,001$), por lo que **se rechaza** H_0 , con intensidad débil (V de Cramér = 0,18). El riesgo relativo es de 2,26 y la razón de momios de 2,68. Son asociaciones crudas: el mayor riesgo observado requiere análisis con ajuste por confusión antes de orientar decisiones clínicas.

4.3 Prueba 3: asociación entre sexo y CHD

$$H_0 : \text{sexo y CHD son independientes} \quad \text{vs.} \quad H_1 : \text{están asociados}$$

Supuestos. Prueba χ^2 de independencia sobre una tabla de 2×2 ; la frecuencia esperada mínima es 276, por lo que el supuesto se cumple.

Resultado. El 18,9 % de los hombres desarrolla CHD, frente al 12,4 % de las mujeres. La asociación es significativa ($\chi^2 = 32,6$; $gl = 1$; $p < 0,001$), por lo que **se rechaza** H_0 , aunque con intensidad muy débil ($V = 0,09$; riesgo relativo de 1,52 y razón de momios de 1,64). La edad media y la proporción de hipertensión son similares entre sexos, pero comparar estos resúmenes no descarta confusión. La asociación no está ajustada y no demuestra una señal independiente. El notebook presenta IC individuales de RR, OR y diferencias de riesgo; Holm mantiene las tres decisiones.




Figura 5: (a) Distribución de la edad por grupo (rombo: media). (b) Tasa de CHD a 10 años según hipertensión prevalente y sexo.

5. Informe de avance del proyecto

En esta fase se revisó la calidad de los datos y se documentó su tratamiento, se caracterizó el conjunto con estadística descriptiva y gráficos según el tipo de variable, se exploraron relaciones bivariadas con variables derivadas, se estimaron parámetros con intervalos de confianza y se contrastaron tres hipótesis con la prueba t de Welch y la prueba χ^2 de independencia. Estos resultados profundizan los de la Formativa 1 y son coherentes con ellos.

Los resultados ofrecen tres lecturas. La **edad** y la **presión arterial** son las señales más claras: el riesgo crece de forma monótona con ambas y se observa un RR crudo de 2,26 para hipertensión. El **sexo masculino** presenta una asociación cruda más débil, pendiente de ajuste. En cambio, el tabaquismo casi no se asocia con el desenlace de forma aislada. Como advertencias, el desbalance del objetivo (15,2 %) exigirá evaluar los modelos con métricas sensibles a la clase minoritaria y no solo con la exactitud, y la colinealidad entre presión sistólica, diastólica e hipertensión obliga a no incluirlas juntas sin más. Los datos son observacionales, por lo que las asociaciones no implican causalidad.

Los **próximos pasos** son imputar los faltantes (glucosa, nivel educativo y cigarrillos por día en fumadores), evaluar el efecto de los valores extremos, evaluar confusión con análisis multivariable, validar las estimaciones mediante remuestreo en la Sumativa 2 y entrenar modelos de clasificación en la Sumativa 3.

6. Notebook y repositorio GitHub

Todo el análisis se realizó en Python con `pandas` (McKinney, 2010), `numpy` (Harris et al., 2020), `scipy` (Virtanen et al., 2020) y `matplotlib` (Hunter, 2007). El cuaderno `Sumativa1_FraminghamHeartStudy_Codigo.ipynb` sigue el mismo orden de este informe, descarga los datos si no existe una copia local, registra SHA-256 y versiones, y genera las tablas y figuras. La semilla es 42. Para Canvas se prepara una copia ejecutada con salidas, mientras el repositorio puede eliminarlas mediante `nbstripout`. El código y los informes de cada evaluación están en el repositorio enlazado en la portada.

7. Bibliografía

- Cohen, J. (1988). *Statistical power analysis for the behavioral sciences* (2.^a ed.). Lawrence Erlbaum Associates.
- Dileep. (s.f.). *Heart disease prediction using logistic regression* [Conjunto de datos]. Kaggle. <https://www.kaggle.com/datasets/dileep070/heart-disease-prediction-using-logistic-regression>
- Harris, C. R., Millman, K. J., van der Walt, S. J., Gommers, R., Virtanen, P., Cournapeau, D., ... Oliphant, T. E. (2020). Array programming with NumPy. *Nature*, 585(7825), 357–362. <https://doi.org/10.1038/s41586-020-2649-2>
- Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering*, 9(3), 90–95. <https://doi.org/10.1109/MCSE.2007.55>
- Mahmood, S. S., Levy, D., Vasan, R. S., & Wang, T. J. (2014). The Framingham Heart Study and the epidemiology of cardiovascular disease: A historical perspective. *The Lancet*, 383(9921), 999–1008. [https://doi.org/10.1016/S0140-6736\(13\)61752-3](https://doi.org/10.1016/S0140-6736(13)61752-3)
- McKinney, W. (2010). Data structures for statistical computing in Python. En *Proceedings of the 9th Python in Science Conference* (pp. 56–61). <https://doi.org/10.25080/Majora-92bf1922-00a>
- Virtanen, P., Gommers, R., Oliphant, T. E., Haberland, M., Reddy, T., Cournapeau, D., ... SciPy 1.0 Contributors. (2020). SciPy 1.0: Fundamental algorithms for scientific computing in Python. *Nature Methods*, 17(3), 261–272. <https://doi.org/10.1038/s41592-019-0686-2>
- Wasserman, L. (2004). *All of statistics: A concise course in statistical inference*. Springer.
- Welch, B. L. (1947). The generalization of “Student’s” problem when several different population variances are involved. *Biometrika*, 34(1–2), 28–35. <https://doi.org/10.1093/biomet/34.1-2.28>
- Whelton, P. K., Carey, R. M., Aronow, W. S., Casey, D. E., Collins, K. J., Dennison Himmelfarb, C., ... Wright, J. T. (2018). 2017 ACC/AHA/AAPA/ABC/ACPM/AGS/APhA/ASH/ASPC/NMA/PCNA guideline for the prevention, detection, evaluation, and management of high blood pressure in adults. *Hypertension*, 71(6), e13–e115. <https://doi.org/10.1161/HYP.0000000000000065>